SYSTEM ARCHITECTURE / REVISION V1.2

轻量级多跳推理 GraphRAG 校园知识问答系统

系统架构设计文档 • 问题清单整改完善版

文档属性	内容
版本 / 日期	V1.2 / 2026 年 11 月 6 日
应用范围	北京邮电大学本科培养方案与学籍规则（教学演示）
交付定位	5 个工作日 + 2 天缓冲 / 单机可复现 MVP
编制依据	产品需求文档 V1.0、系统架构设计 V1.1 问题清单、课题要求
文档用途	前后端、图谱、检索与测试工程师的统一设计依据

本轮修订重点

- 保留宏观架构和模块协作主线；将字段契约、示例 JSON、部署约定放入短附录。
- 新增 7 项 P0 闭环约束：图谱 Schema、逐边溯源、完整路径、批次发布、关系核验、部署基线、断言引用校验。
- 补齐 P1 联调与评测约定；明确向量检索/生成模型降级以及性能目标与实测的区别。

决策边界 本文件中的模型版本、索引组织方式、SQLite 元数据表和批次发布属于推荐实现方案，不是课题唯一指定技术；真实语料、硬件实测与测试集标准答案须在 D1 签核，不以演示数据冒充事实。

一、需求背景与目标

1.1 项目目标及约束

面向培养方案、课程类别与学籍规则等跨文档问题，系统通过“实体锚点 → 2—3 跳关系路径 → 逐边来源 → 受约束回答”完成可解释问答。架构重点是路径可达性与证据可核验，而非大规模图谱建设或大模型性能竞赛。

必须完成（P0）	本期边界
文档解析、实体关系入库、逐边来源映射	仅已授权公开文档或明确标注的脱敏模拟资料
2—3 跳路径检索与完整性校验	不做开放式任意图推理；路径类型有限
引用支持的答案及证据路径展示	无完整可信证据不得输出确定性制度结论
单机 Docker Compose 启动	不依赖付费外部 API；不接入正式教务系统
⩾10 道冻结多跳题、3 项核心指标	不做全校知识图谱及生产级高并发

1.2 验收原则

成功响应至少提供 1 条符合问题语义约束的完整 2—3 跳路径，路径每条边具有已核验原文证据，并可追溯到文档、版本与章节/页码。知识版本冲突、关系未核验或引用缺失时，一律不得判为 success。前端展示路径不代表原始制度自动真实有效。

1.3 P0 / P1 分界

P0 允许采用“导入样例 → 人工预核验关系 CSV → 生成验证标志 → 批次发布”的轻量流程，不要求建设审核管理后台。P1 再加入审批流、关系批量编辑、历史版本管理和增量重建。P2 考虑多轮追问、自由图探索及更丰富的召回器。

二、技术选型说明

层次	选型	采用方式 / 取舍
交互层	Vue 3 + Vite	问答、证据展开、知识库上传、评测看板；交互阶段由前端管理
业务层	FastAPI / Python 3.11	统一请求、范围补齐、编排检索、输出校验及业务终态
图存储	Neo4j Community 5.x	实体、五类方向关系和 batch_id；约束可检验
元数据	SQLite	文档/Chunk/关系证据映射、构建批次与 active_version 指针
文本召回	bge-small-zh-v1.5 + FAISS	默认采用，索引按 batch 隔离；不可用可显式降级 graph_only
本地生成	Ollama + Qwen2.5 1.5B	仅改写经验证事实；离线不可用时优先模板生成
部署	Docker Compose	Web、API、Neo4j、Ollama；FAISS 随 API 持久化，不另起服务

轻量化策略：优先保证图谱遍历、关系可信和证据校验；本地小模型只负责语言表达，不能替代图路径核验。若实验机算力不足，先减小生成模型/候选数，必要时关闭向量召回，但不得删除逐边引用与拒答。

三、总体架构设计

3.1 分

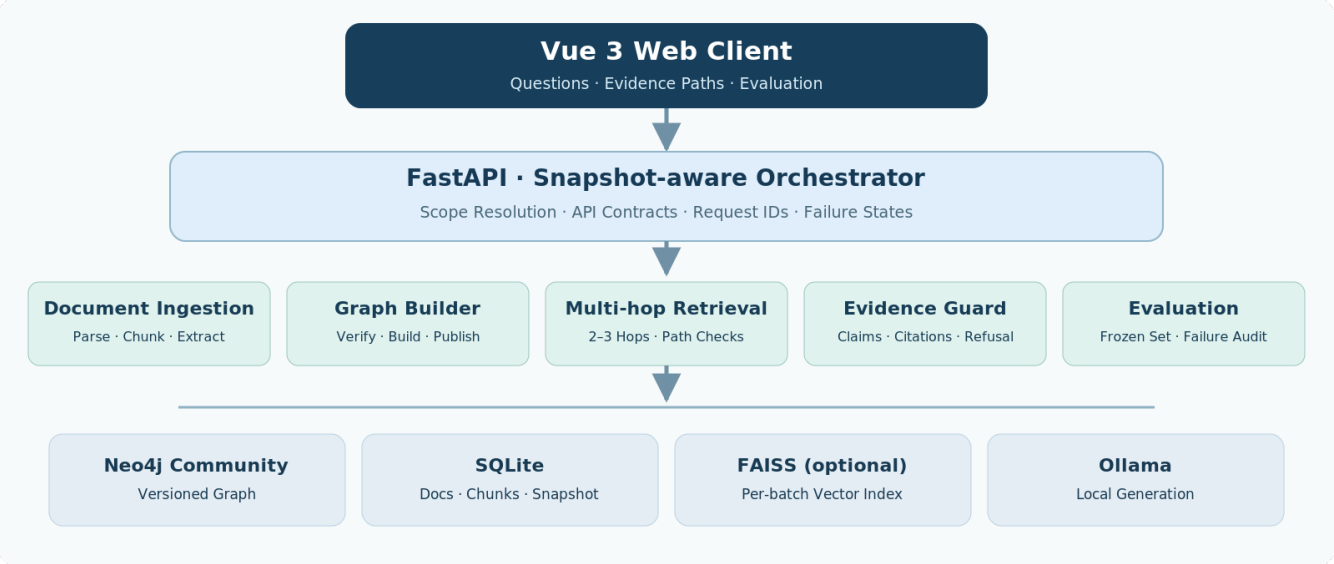


图 1 单机部署下的核心模块及依赖关系

3.2 模交付界

模块 / 责任方	实现方法	提供给其他模块
前端交互 / FE	筛选专业与入学年级、调用 /qa/ask、呈现节点边/引用/失败态	传递 scope；使用唯一 JSON 契约展示路径
文档摄入 / BE+Data	PDF/DOCX/TXT 解析；Chunk 切分；词典/规则抽取，模型辅助候选	doc_id、版本、chunk_id、候选关系
图谱构建 / Data	白名单映射、人工预核验、Neo4j MERGE、批次校验发布	批次隔离的图谱与关系证据
混合多跳 / BE	实体词典 + 可选 FAISS，模式约束遍历并验证路径终点	2—3 跳完整、可复核 path_ids
生成校验 / BE	提取确定性事实，模型结构化转写，断言-引用双向检查	success / needs_context / insufficient / error
评测与运维 / QA+BE	冻结 JSONL、逐跳诊断、3 项指标、运行资源日志	可复算报告、失败分布和运行批次

3.3 服务与数据交互约定

浏览器只调用 FastAPI，不直接访问 Neo4j、SQLite、FAISS 或 Ollama。API 请求开始时读取并固定 knowledge_batch，在本次请求内所有节点、边、Chunk、向量候选均来自同一批次；生成与校验使用相同的证据对象。构建任务写入 staging，验证后才切换 active_version。

四、关键实现方案

4.1 文档摄入与批次发布

处理顺序：上传与授权检查 → 格式解析与文件哈希去重 → Chunk 分割并记录页码/章节 → 词典与规则为主的实体关系候选抽取 → 关系白名单检查及预核验 → 写入 staging 图谱/FAISS/元数据 → 检查可追溯性与版本 → 原子切换 active_version。失败批次标为 failed，不能进入问答。

PDF 若仅含扫描图片且无可提取文字，P0 返回解析失败与定位信息，不隐式承诺 OCR；样例需优先使用可解析版本。更新文档时可在 staging 全量重建小规模样例，不在活跃索引上直接修改。

4.2 多跳问答与"完整路径"判定

问题类型	目标关系链（按语义关系计数）	判定条件
T1 · 2 跳 / 方案规则	ProgramPlan → CONTAINS → CourseCategory → CITES → RuleClause	锁定方案、年级、规则条款终点
T2 · 3 跳 / 专业规则	Professional ← APPLIES_TO ← ProgramPlan → CONTAINS → CourseCategory → CITES → RuleClause	专业/年级明确，终点是对应条款
T3 · 2 跳 / 先修链	Course → PREREQUISITE_OF → Course → PREREQUISITE_OF → Course	两段先修关系均在来源中存在

输入先解析 question_intent、anchors 和 scope（专业、入学年级/版本）；缺少决定适用性的字段返回 needs_context。仅以模式白名单扩展，默认最多 3 跳、每跳最多 10 个候选、总路径最多 20 条；对候选执行终点类型、关系序列、方向、batch、verified、逐边 evidence 与年份一致性检查。任意连通的 2 跳并不等于能回答该问题。

排序优先级：目标链完整性与适用范围匹配 > 逐边来源覆盖和证据质量 > 路径长度/检索分值。发现一条无冲突、全证据完整路径后可停止扩展；若同范围可信条款出现无法解释的冲突，返回 insufficient 并提示冲突，不能任选一个。

4.3 证据约束生成、拒答与降级

后端先把合格路径映射为可核验 fact_records（实体、关系、范围、条款与证据 ID）；模型仅以这些事实生成 claims。每个关键 claim 必须引用 path_ids，且其 citation_ids 覆盖所依赖路径的每条 relation_id。后端重新校验引用存在、来自同批次、verified 与事实槽位一致；发现额外未授权数值、引用缺项或不一致时，回退模板或返回 insufficient。

触发条件	后端终态 / 执行策略
scope 缺专业/入学年级	needs_context：missing_fields，前端引导补充
无法形成可信完整路径 / 条款冲突	insufficient：不给确定性结论，记录断链跳次
生成模型不可用；已有全量事实槽位	success：使用固定模板，degraded_mode=true；显示"模板降级"
生成模型不可用；事实不能安全模板化	error 或 insufficient；不凭推测补充内容
FAISS 不可用；实体与图谱路径完整	success 可允许，retrieval_mode=graph_only 且标识降级
Neo4j/元数据不可用	error：明确服务错误与 request_id

4.4 API 及前后端状态边界

基础端点：POST /qa/ask；POST /documents；GET /evidence/{citation_id}；POST /evaluations/run；GET /evaluations/{run_id}；POST /feedback。详细字段按附录 C 执行，路径接口支持 evidence 按需读回与访问权限检查。错误响应包含 request_id，可关联服务器日志。

前端执行阶段（UI）	后端业务终态	前端显示
idle / searching / generating	尚未返回最终结果	输入待命 / 搜索动画 / 生成动画
完成请求	success	答案 + 节点边 + 来源；降级标识可见
完成请求	needs_context	提示补全专业或入学年级；保留问题
完成请求	insufficient	解释缺失证据、失败跳次或冲突，不展示确定结论
完成请求	error	服务错误提示与 request_id，可重试

五、风险、取舍与应急预案

风险	主线应对	可接受降级 / 禁止行为
抽取质量造成断链	限定词典与关系白名单；样例语料人工预核验	保留断链原因；不能自动伪补关系
图谱与向量索引版本不齐	整批 staging 构建、校验、切换；查询固定 batch	允许 graph_only，但必须显式标识
模型输出与来源错位	事实槽位 + claims/path_ids/citations 校验	模板生成或拒答；不得“先回答后补引用”
CPU 性能不足 / 模型挂起	紧凑模型、限制 token/候选、超时保护	延迟按实测披露；不放弃核心五类能力
文件权限与提示注入	白名单格式、容量限制、只读证据、日志脱敏	原文仅作为数据，不能覆盖系统规则

六、测试计划与实施里程碑

6.1 验收测试与指标

D1 冻结 ⩾10 道已标注真实/明确标注模拟证据的多跳题，其中 2 跳与 3 跳各不少于 4 道；每题记录 gold_relation_path、doc_version、expected_status。正式评测数据与额外无证据/服务故障负例分开报告，避免改变三项指标分母。

指标（与 PRD 一致）	计算口径 / 输出
路径命中率	标准关系链被完整匹配的题数 ÷ 冻结多跳题总数
答案正确率	符合金标准结论/预期终态的题数 ÷ 冻结多跳题总数
引用覆盖率	拥有可读回来源的关键断言数 ÷ 全部关键断言数；无断言则记 N/A
失败分析	首跳未召回 / 后续跳缺失 / 版本冲突 / 引用缺失 / 模型误用 / 合理拒答

性能目标（非原题硬门槛）：首页首屏 ≤3 s、图检索 P95 ≤5 s、问答 P95 ≤20 s；测试报告写明 CPU/GPU、并发、热启动、每题重复次数、样本数和实测值。10 题样本不足以稳定估计 P95，不得以单次数值宣称满足性能 SLA。

6.2 D1—D5 + 2 天缓冲

阶段	交付结果 / 检查点
D1 · 冻结设计与资产	样例语料清单、关系白名单、图谱 Schema、测试题/评分协议、硬件与模型镜像基线；完成范围签核
D2 · 图谱与来源	可查询节点/边；每条可答关系具 evidence、verified 与 batch；构建失败不可发布
D3 · 多跳与守卫	T1—T3 闭环、路径完整性、claims/citations 校验与 needs_context/insufficient
D4 · 前后端联调	四态 Mock、证据弹层、模型/FAISS 故障模拟、请求 ID 与反馈
D5 · 冻结题正式评估	仅运行 D1 冻结题集，产出逐题失败分析、资源与启动复现记录
缓冲第 1—2 天	修复缺陷、回归与答辩彩排，不更换金标准或擅自扩展场景

七、实施附录（工程契约）

附录用于约束模块对接，而不替代各工程师的代码级详细设计。所有结构化示例均为模拟 ID，不表示北邮已确认的课程、制度数值或实际入库结果。

附录 A 图谱 Schema 与查询模式

A.1 节点类型与唯一键

Label / 中文	关键属性（必需）	全局业务 ID 示例
College / 学院	entity_id, name, college_code	college:<code>
Professional / 专业	entity_id, name, major_code, college_code	major:<code>
ProgramPlan / 培养方案	entity_id, name, major_id, entry_year, plan_revision	plan:<major>:<year>:<rev>
CourseCategory / 课程类别	entity_id, name, plan_id, category_code	category:<plan>:<code>
Course / 课程	entity_id, name, course_code	course:<code>
RuleClause / 规则条款	entity_id, name, doc_id, doc_version, section	rule:<doc>:<ver>:<section>

所有节点另带 batch_id 和 node_key = batch_id + ":" + entity_id。Neo4j Community 为六类 Label 分别建立 node_key UNIQUE 约束。不同批次即使业务实体相同，物理节点也不共用，以保证快照隔离。

A.2 五类关系白名单（存储方向固定）

关系（代码）	合法起点 → 终点	关系必需属性 / 语义
所属 BELONGS_TO	Professional → College；Course → CourseCategory	relation_id, batch_id, verified, evidence_chunk_ids；课程归类

关系（代码）	合法起点 → 终点	关系必需属性 / 语义
包含 CONTAINS	ProgramPlan → CourseCategory；CourseCategory → Course	同上；计划包含类别/类别包含课程
适用 APPLIES_TO	ProgramPlan → Professional；RuleClause → ProgramPlan	同上；方案适用专业/条款适用方案
引用 CITES	CourseCategory → RuleClause；ProgramPlan → RuleClause	同上；某类别或方案引用条款
先修 PREREQUISITE_OF	Course → Course	同上；A → B 表示 A 是 B 的先修课

每条边的 relation_id 由“batch_id + 起点 entity_id + 类型 + 终点 entity_id + scope”确定性生成。相同关系可关联多个 Chunk。用 MERGE 防重并在导入层检查 relation_id 唯一；Community 版不假定具备企业级关系唯一约束。关系反向遍历只改变查询方向，不改变原关系语义。

A.3 3 跳模式及可运行 Cypher 模板

结构示例（非真实入库）：Professional ← APPLIES_TO ← ProgramPlan → CONTAINS → CourseCategory → CITES → RuleClause，共 3 条语义边。查询中的 major_key、batch_id、entry_year 由 API 传入。

```
MATCH (m:Professional {node_key:$major_key})
      <-[r1:APPLIES_TO]-(p:ProgramPlan)
      -[r2:CONTAINS]->(c:CourseCategory)
      -[r3:CITES]->(q:RuleClause)
WHERE p.entry_year = $entry_year
  AND all(n IN [m,p,c,q] WHERE n.batch_id = $batch_id)
  AND all(r IN [r1,r2,r3] WHERE r.batch_id = $batch_id
       AND r.verified = true AND size(r.evidence_chunk_ids) > 0)
RETURN m,p,c,q,r1,r2,r3 LIMIT 20
```

该查询只能产生候选路径；发布前与回答前仍需到 SQLite 检查每个 evidence_chunk_id 的文档存在性、授权访问、版本与批次一致性。实际业务数值必须从证据中读取，不可由此模式推断。

附录 B 证据、信任与版本契约

B.1 最小元数据字典

对象	标识 / 关键字段	一致性约束
Document	doc_id, doc_version, title, source_uri, file_sha256, access_level, publish_state	同一 batch 内有明确的适用年级与版本
Chunk	chunk_id, doc_id, doc_version, batch_id, page_start/end, section, text, text_sha256	原文保留；支持按 citation_id 读回；无页码则保留章节/段落定位
RelationEvidence	relation_id, chunk_id, batch_id, verification_status, verified_by, verified_at	逐边至少一个 verified 来源；无来源/未核验不得 success
BuildBatch	batch_id, state, source_manifest_sha, graph_count, faiss_index_sha, checked_at	staging / validated / active / failed / retired
ActiveSnapshot	project_key, active_version (= batch_id), switched_at	切换指针事务化；查询开始读取一次并固定

B.2 审核与发布时序

P0 样例预核验：数据工程师生成关系清单（CSV）→ 指定核验人根据原文逐边确认 → 写 verification_status=verified、verified_by、verified_at；含断链、无来源或跨版关系保留为 unverified/rejected，不参与肯定性回答。完整后台审批流仍属 P1。

发布：构建新的 batch（图节点与边、Chunk、独立 FAISS index）→ 检查节点约束、每边来源、向量索引元信息与覆盖题样本 → 标记 validated → SQLite 事务切换 active_version → 新查询采用新批次；在途查询继续使用已固定旧批次，结束后再清理。中断/失败仅保留 staging/failed，不暴露半成品。

版本冲突策略：先按专业、入学年级与有效状态过滤；同范围存在互斥且均可信的规范内容时，不任意使用发布时间较新的条款覆盖旧内容，返回 insufficient 并呈现冲突来源。若未给出适用年级，返回 needs_context。

B.3 3 项强制校验

- 可溯源：每个被使用的 relation_id 至少映射一个可读回的 verified Chunk。
- 可隔离：paths、citations、FAISS 候选与所有节点/边 batch_id 全部等于请求 knowledge_batch。
- 可核验：每条关键 claim 的引用集合覆盖其所依赖路径的每条边；缺任意引用不得 success。

附录 C API JSON 契约（前后端联调）

C.1 统一返回结构

POST /qa/ask 接收 {question, scope: {major_code, entry_year}}。四种终态 success / needs_context / insufficient / error 返回相同顶层键：request_id、status、knowledge_batch、retrieval_mode、degraded_mode、degradation_reason、answer_mode、answer、claims、paths、citations、missing_fields、error。业务终态正常使用 HTTP 200；基础设施不可用使用 HTTP 503 且 status=error。

字段	含义 / 约束
paths[n]	path_id, hop_count, nodes[{node_id,label,name}], edges[{relation_id,type,from,to}]；一条语义边计一跳
claims[n]	claim_id, text, path_ids[], citation_ids[]；每项关键断言须关联有效完整路径
citations[n]	citation_id, relation_id, chunk_id, doc_id, doc_version, section, page, excerpt；细节允许按需读回
error	code, failed_hop, retryable；未发生错误时为 null
retrieval_mode / degraded_mode	hybrid 或 graph_only / boolean；使用 graph_only 或 template 时必须 true

C.2 四种业务终态 Mock

完整四态 Mock 文件随文档另附：GraphRAG_问答接口四态 Mock_V1.2.json。以下为联调时最重要的响应骨架；示例文本与编号均为模拟。

```
// success · HTTP 200（完整节点/边/引用数据详见附带 Mock）
{"request_id":"req-demo-001","status":"success","knowledge_batch":"batch-demo-01",
 "retrieval_mode":"hybrid","degraded_mode":false,"answer_mode":"llm",
 "claims":[{"claim_id":"claim-1","path_ids":["p-1"],
            "citation_ids":["cit-1","cit-2","cit-3"]}],
 "paths":[{"path_id":"p-1","hop_count":3,"nodes":["...4 nodes..."],
           "edges":["...3 typed edges..."]}],
 "citations":["...3 original-text locations..."]}
```

```
// needs_context · HTTP 200
{"request_id":"req-demo-002","status":"needs_context",
 "missing_fields":["entry_year"],"paths":[],"claims":[],"citations":[]}
// insufficient · HTTP 200
{"request_id":"req-demo-003","status":"insufficient","retrieval_mode":"graph_only",
 "degraded_mode":true,"paths":[],"claims":[],"citations":[],
 "error":{"code":"PATH_INCOMPLETE","failed_hop":2,"retryable":false}}
// error · HTTP 503
{"request_id":"req-demo-004","status":"error","paths":[],"claims":[],"citations":[],
 "error":{"code":"GRAPH_UNAVAILABLE","failed_hop":null,"retryable":true}}
```

约束：前端按 status 显示四态；渲染路径只读 paths，不从 answer 文本猜测关系。GET /evidence/{citation_id} 必须按当次记录的 knowledge_batch 读取 Chunk，且对不可公开的证据执行权限检查。列表类 /documents、/evaluations 使用 limit/offset 并返回 total。

附录 D 评测集与单机部署基线

D.1 测试集数据契约 / 冻结规则

资产	最低字段 / 操作规则
questions_v1.jsonl	question, scope, gold_answer, gold_relation_path, hop_count, doc_version, expected_status；另存 question_id 与 source_evidence_ids
records.jsonl	question_id, request_id, batch_id, predicted_path, path_hit, answer_correct, citation_covered, failure_stage, elapsed_ms
题型分布（建议）	T1 2 跳至少 4 题；T2 3 跳至少 4 题；剩余 2 题可按有证据语料决定 T1/T2/T3
冻结/评分	D1 锁定文件哈希和判分脚本版本；D5 只执行及记录，禁止事后修改金标准
负例集（单独统计）	漏年份、关系未核验、无证据、文档冲突、索引不一致、模型中断、图不可用

D1 输入资产尚未提供：请补齐最终样本文档清单（来源 / 授权 / 文件哈希 / 专业 / 入学年级 / 版本）和经过来源支持的金标准路径。本文不虚构学校真实“学分、替代上限或先修规则”。若真实语料没有“替代”关系及上限条款，不能将该问题列为成功验收题。

D.2 推荐单机部署“候选锁定”

资源与组件	工程基线（建议 D1 实测签核）
最低实验环境候选	4 vCPU / 16 GB RAM / ≥25 GB 可用磁盘；CPU 可运行；有 ≥6 GB 显存独显为可选加速
容器镜像（候选）	neo4j:5.26.0-community；ollama/ollama:0.5.7；python:3.11-slim；node:20-alpine + nginx:1.27-alpine
模型/依赖（候选）	Qwen2.5:1.5b（Ollama tag qwen2.5:1.5b）；BAAI/bge-small-zh-v1.5；锁 requirements 与模型缓存 SHA

资源与组件	工程基线（建议 D1 实测签核）
持久卷	neo4j_data、ollama_data、app_data(SQLite)、faiss_indexes、model_cache、doc_uploads
启动健康检查	Neo4j Bolt 可连通 / API /health/live 与 /health/ready / active batch 完整 / Ollama 模型可请求
低配降级	生成改 qwen2.5:0.5b 或模板；降低 max_tokens；向量服务不可用时 graph_only；模型基线变更需记录

候选镜像/模型标签不是实测通过的声明。D1 应在实际机器执行拉取、内存占用与端到端 2 跳问答后，记录镜像 digest、模型 SHA、CPU/内存/GPU 信息、Python lockfile 校验值，形成最终可复现 README。

D.3 启动顺序与验收操作

- 1 复制 .env.example → 固定容器镜像/资源限制/卷路径；所有数据库端口仅开放内部 Compose 网络。
- 2 docker compose up -d neo4j ollama；docker exec <ollama-container> ollama pull qwen2.5:1.5b；预下载并校验本地 embedding 文件。
- 3 建立 Neo4j 节点唯一约束、初始化 SQLite、启动 API/Web；显示 /health/ready 的各服务和 active_version。
- 4 导入 D1 授权样例 → 构建 staging → 校验证据/索引 → 发布批次；通过 /qa/ask 完成一次 2 跳成功与一次拒答。
- 5 中断构建、关闭 Ollama 与 FAISS，验证旧快照仍可用、模板降级与 graph_only 标识、故障日志可追踪。

D.4 验收报告说明

记录冷/热启动、单并发与重复次数、P50/P95、API/图检索时延、峰值 RSS/VRAM、模型与索引批次。性能阈值为设计目标，最终报告应并列列出目标值和实测值；数据量不足时披露小样本局限。

附录 E 问题清单对应整改索引

问题编号	整改位置 / 责任边界
A-01 / A-02	附录 A Schema；附录 B 逐边来源与 Chunk 映射
A-03 / A-04	§4.2 完整路径；附录 B 构建批次与 active_version
A-05 / A-06	§1.3 P0 预核验；附录 D 部署基线
A-07 / B-01	§4.3 断言校验；附录 C 四态 API Mock
B-02 / B-03	附录 D 测试集、样本清单与真实来源检查
B-04 / B-05	§4.3 降级；§4.4 状态分层；§6.2 题集 D1 冻结
C-01 / C-02	§2、§5 FAISS 降级；§6.1、附录 D 性能目标/实测

参考材料

《轻量级多跳推理 GraphRAG 校园知识问答系统 PRD V1.0》（2026-11-05）；《GraphRAG 架构设计问题清单 V1.0》（2026-11-06）；《AI 实践复杂项目选题》（GraphRAG 课题部分）；《系统架构设计文档》七章结构模板。